

SSAFY 16기 2회차 AI 챌린지

Team 자, 이게 AI라는 거야

이창엽 · 윤종서 · 이정아 · 정소향 · 차가민

CHALLENGE

같은 조건에서, 무엇을 바꿔야 성능이 달라질까?

같은 문제를 풀기 때문에, 어떻게 실험하고 비교할지를 먼저 정했습니다.

Task

Image + Question + Choices 입력
이미지 정보와 질문을 함께 이해
정답 문자 1개 출력

Starting Point

모든 팀이 동일 데이터·목표
주최 측 Qwen2.5 기반 코드 제공
모델·학습 전략을 각자 개선

우리 팀의 질문

무엇을 바꿀 것인가?
어떻게 공정하게 비교할 것인가?
짧은 기간에 탐색 범위를
어떻게 넓힐 것인가?

같은 출발점이라면, 차이는 “실험을 어떻게 설계했는가”에서 만들어집니다.


모델은 다양하게 — 계산 자원을 나누어 병렬 탐색

한 모델에 몰기보다 GPU 환경과 모델 특성에 따라 탐색 범위를 나눴습니다.



고성능 모델 탐색 2명

A100 / 고메모리 GPU 활용
상대적으로 큰 모델과 Scale-up 가능성 확인
고성능 후보 및 Expert 후보 탐색



이창엽




윤종서




경량·효율 모델 탐색 3명


Colab 기본 / Local 환경 활용
모델 크기·버전·양자화를 달리해 반복 실험
팀 내 동일 조건 중복을 줄이고 후보군 확대



이정아



정소향



차가민

한 모델의 최고점보다, 팀 전체가 더 넓은 후보 공간을 검증하는 데 초점을 맞췄습니다.

공통 Baseline 설계

모델이 달라도 비교 기준이 같도록 기준 성능과 재현 가능한 실험 절차를 먼저 만들었습니다.

① 공정하게 비교

같은 학습·검증 분할
같은 문항·채점 기준
같은 이미지는 한쪽 Split에만 배치

② 학습 효과 구분

학습 전 → 학습 후
모델·설정별 변화 추적

③ 실험 결과 추적

정확도·예측·오류
추론 시간·메모리·실행 상태

6,714

전체 Train



5,371

Train 80%

+

1,343

Validation 20%



Before
학습 전 평가

Training
학습

After
같은 Validation
재평가

공통 Baseline = 기준 성능 + 재현 가능한 실험 절차

PROCESS

3일 과정

탐색 → 검증 → 개선 반복

DAY 1

탐색

데이터 분할·Baseline 구축

팀원별 모델 선정

GPU 환경별 역할 분담

Smoke 실행



DAY 2

학습·검증

LoRA / QLoRA 학습

양자화·학습 설정 조정

Pilot / Full 실행

모델별 정확도 비교



DAY 3

결과 분석

문항별 오답 비교

Ensemble 적용

Disagreement Sample 분석

Expert Routing 방향 검토

Smoke 코드·GPU 실행 확인

Pilot 표본을 늘려 설정 비교

Full 최종 후보 전체 학습

START → VALIDATE → IMPROVE

모델 검증 과정

시작 전략 이후, 학습 가능성부터 모델 비교와 확장성까지 단계적으로 검증했습니다.

CHOICE 01

학습 환경 검증

제한된 GPU에서
반복 실험 가능한가?

양자화 · 경량 학습

실행 가능한 학습 환경 확보

CHOICE 02

모델 성능 비교

이전 세대 7B vs
이후 세대 4B

동일 기준으로 실제 성능 비교

성능·효율을 기준으로 모델 선정

CHOICE 03

Scale-up 검증

모델을 키우면
성능도 계속 좋아질까?

27B → 더 큰 모델로 확장

Bigger ≠ Better → Ensemble / Expert

자원 제약 해결 | 모델 후보 검증 | 개선 방향 도출


단순히 큰 모델을 선택하기보다, 실제 실행 가능성과 성능을 확인하며 다음 실험 방향을 결정했습니다.

CHOICE 01

직접 양자화를 시도하지 않고, 이미 최적화된 사전 양자화 모델을 가져왔습니다.

BF16 대비 4-bit 양자화를 통해 메모리 사용량을 대폭 절감하고 실행 가능성을 높였습니다.

✓ Qwen3.8-27B 모델 크기 (GB)



huggingface.co/Qwen/Qwen3.8-27B
huggingface.co/btbyler09/Qwen3.8-27B-GPTQ-4bit

2.6×

메모리 절감 (BF16 → 4-bit)

BF16 원본 약 28B params × 2 Byte ≈ 56 GB

GPTQ 4-bit FOEM ≈ 21 GB

텍스트 디코더 ≈ 19 GB, Vision Encoder·MTP는 BF16 유지


성능 저하를 막기 위해 가중치를 쪼개어 관리하면서, 가중치당 평균 4.85-bit로 압축했습니다.

CHOICE 02

모델 크기와 버전을 기준으로 성능을 비교했습니다

이전 세대 7B vs 이후 세대 4B · Pilot Validation 128문항 기준


✓ Qwen2.5-VL-7B



+0.78%p | +1문항

✓ Qwen3.5-4B

BEST



+84.38%p | +108문항

Fine-tuning(학습)을 통한 최종 성능 측면에서는 모델 크기보다 버전이 더 중요했습니다.

CHOICE 03

Bigger Model ≠ Better Model

단순 Scale-up의 한계를 확인하고 285개 오류 집중 타겟팅으로 방향을 전환했습니다.

가설

27B 모델 정확도 0.959
더 큰 35B MoE 모델 도입 시
비례적인 성능 향상 기대



실험

Qwen3.6-35B MoE

Zero-shot 128개 검증: **0.9141**
추론 속도: 장당 11.5초
Fine-tuning 예상 시간: 약 55시간



관찰

모델 크기 증가가 성능 향상을
보장하지 않음
연산 자원·시간 비용 과도
전체 데이터 일괄 추론은 비효율

전략 전환

~~전체 Sample → 거대 모델 일괄 재추론~~



285개 핵심 오류 데이터 집중 → Expert Routing

전체를 거대 모델로 추론하지 않고, 기존 모델이 실패한 285개 문항에 계산 자원을 집중합니다.


RESULT 01

학습은 실제로 얼마나 개선했는가?

학습 전후 정확도를 비교했습니다.

Gemma 4 26B A4B


Validation 1,343문항



1차 학습
+1.04%p
+14문항
추가 학습
+0.07%p
+1문항

Qwen3-VL-4B


Validation 1,343문항



1차 학습
+2.83%p
+38문항

Qwen2.5-VL-7B


Pilot 128문항



1차 학습
+0.78%p
+1문항

Qwen3.5-4B

Pilot 128문항




1차 학습
+84.38%p
+108문항

개별 모델에서 Ensemble로

전체 정확도뿐 아니라 “어떤 문항을 서로 다르게 맞혔는가”를 확인했습니다.

✓ 문항별 정답 비교

Qwen3-VL-4B vs Gemma 4 26B A4B · Validation 1,343문항



둘 다 정답 1,261문항 · **둘 중 하나라도 정답 1,324문항 (98.59%)**

※ 위 수치는 Ensemble 정확도가 아니며, 결합 규칙의 성능은 별도로 검증해야 합니다.

Single Best

0.96365

Ensemble



0.96812

+0.00447 ≈ +0.45%p

성능 좋은 모델 하나를 고르는 것에서
모델 간 판단을 조합하는 방향으로 확장

모델 밖에서도 문제가 있었습니다 — Data Quality

정상 데이터로 분류된 Sample에서도 Label 오류 사례를 발견했습니다.



높은 Validation 정확도만으로 실제 Visual Understanding 성능을 모두 설명할 수는 없습니다.

285개 난제 해결을 위한 Expert Router 구축

최적 후보 모델 스크리닝부터 122B 최종 판별 모델 투입까지의 다단계 프로세스

STEP 01

후보 모델 신속 벤치마크

대상

Agnes, Occamy 후보군

평가

285개 난제 Zero-shot 검증

측정

문항당 추론 속도 및 VRAM



STEP 02

1차 필터링 및 즉시 탈락

정확도

기준 미달 모델 즉시 탈락

오류 패턴

기존 모델과 중복 시 탈락

비용

과도한 추론·학습 시간 탈락



STEP 03

생존 모델 집중 Fine-tuning

심층 추론

285 Hard Set 전체 평가

선정

최적 1개 모델 최종 선정

학습

선택 모델 단독 Fine-tuning



STEP 04 (FINAL)

122B Expert 최종 Ensemble

선별

모델 간 판단 불일치
Sample 추출

투입

122B Expert 모델 최종 판별


완성

선택적 재판단 Router 구축 완료

NEXT

현재에서 다음 단계로

지금까지의 실험을 Error Diversity와 선택적 Expert 구조로 확장합니다.






더 큰 하나의 모델보다, 서로 다른 모델을 필요한 문제에 적절히 활용하는 구조로 발전시킵니다.

THANK YOU

APPENDIX

학습 곡선 · 실행별 loss 변화

loss 절대값만으로 모델 순위를 판단하지 않고, 검증 정확도·오답 변화와 함께 확인했습니다.



Gemma 추가 학습: 최종 검증 loss 0.05572 → 0.05908, 정확도는 +1문항.
손실 감소만으로 일반화 개선을 판단하지 않고 검증 정확도·오답 변화를 함께 확인했습니다.